A1.1 交通标志识别任务级攻击实验

GTSRB · 试点运行记录（非论文数据）

配置：32 px 丨 集成 sresnet,svgg,ssep 丨 未见目标 sinc 丨 测试样本 600 丨 T=15 丨 ε=0.0627

一、这一轮做了什么

把《T-ITS 投稿补充方案》里的 A1.1 落成可运行的代码，并在本机跑通全链路：训练替代模型 → 生成对抗样本 → 在集成内目标与未见目标上分别统计 → 按交通语义加权算指标 → 提取混淆对。目的是先把「攻击做成什么、指标怎么算」这两件事定下来，而不是产出论文数字。

本机没有 NVIDIA 显卡（仅 Intel UHD 620），因此采用 32 px + 4 个架构互异的小网络 + 12 000 幅训练子集的缩减配置。这个配置得出的绝对数值不能写进论文，但它足以验证代码正确性与指标行为，且与正式配置共用同一套脚本。

二、指标：为什么 ASR 不够

ASR 只回答「有没有骗过」，不回答「骗得有多危险」。把限速 80 读成 30 是效率损失，把限速 30 读成 80 是违法与事故，两者在 ASR 里是同一个 1。因此按交通语义给混淆对赋权：

表 1　SW-ASR 的六档语义权重（v2）

语义档位	权重	典型混淆对	交通后果
严重放宽	1.0	限速 30 → 限速 80；停车让行 → 干道优先；禁止超车 → 解除禁止超车	可直接导致超速、闯停、违规变道
明显放宽	0.8	限速 30 → 限速 50；右转 → 左转	需驾驶员纠正，否则走错或抢行
同族混淆	0.5	行人 → 儿童；警告 → 另一类警告	风险量级相当，仍保留警示
更严格	0.3	限速 80 → 限速 30	安全侧错误，仅效率损失
误刹车	0.2	限速 80 → 停车；干道优先 → 停车让行	不超速，但幽灵急停本身是追尾诱因
无害提示	0.1	信号灯 → 一般危险警告	只让车减速，几乎无危害

v1 曾把「任何标志 → 停车 / 一般警告」一律记 0，认为那是安全侧、不必惩罚。这条规则过宽：把限速 80 读成停车标志，车辆会在高速路段无故急停，本身就是追尾诱因；把信号灯读成「一般危险警告」也会造成不必要的制动。v2 起 0 只留给对角线（预测正确），安全侧错误统一落在 0.1～0.3 的低风险档。改动使 SW-ASR 绝对值整体上移约 0.01～0.02，四种攻击的相对次序与结论均未改变。

在此基础上定义两项指标：SW-ASR = 加权命中率；DMR = 权重 ≥ 0.8 的样本比例（只数危险那一档）。两者与 ASR 并列报告，不替代 ASR。

三、试点结果

先看干净准确率，确认替代模型本身是有效的：

sresnet 94.5%；svgg 97.0%；ssep 90.8%；sinc 96.2%。四个模型均在 43 类上训练，未见目标（sinc）从未参与对抗样本生成。

表 2　四种攻击在 GTSRB 上的表现（试点配置）

攻击	集成内 ASR/%	SW-ASR/%	DMR/%	未见目标 ASR/%	未见 SW-ASR/%	L_2	SSIM	ms/样本
I-FGSM	47.4	24.3	9.9	34.8	19.0	2.94	0.817	87
NAE	46.8	24.3	10.1	34.8	18.9	3.06	0.803	85
DI-NI-FGSM	44.8	22.9	9.2	34.8	18.9	3.10	0.797	86
RNTME-NAE	63.4	32.7	14.7	34.3	18.7	3.13	0.830	716

3.1 两个必须看的对比

第一个对比是集成内与未见目标。RNTME-NAE 在集成内达到 63.4%，比最强基线（47.4%）高 16.0 个百分点；但在完全未参与生成的 sinc 上，它只有 34.3%，而基线最高为 34.8%——优势归零，甚至略低。

这个结果不能忽略。它意味着 RNTME-NAE 的提升高度依赖「被优化过的模型」：只要模型参与梯度加权，成功率就大幅上升；换成一个架构相似但从未见过的模型，收益消失。换句话说，在集成成员上测出来的数，衡量的是拟合能力，不是迁移能力。原稿的 85.0% 正是在集成成员上测的，这条试点结果与之前的文本审查指向同一个问题，只是这次是实验证据而不是推理。

必须说明的是，试点只有 1 个未见目标、1 个种子、32 px 输入，不能据此断言「全量下也没有优势」。但它把风险具体化了：正式实验必须把未见目标的结果与集成内结果并排报告，且不能只报后者。

3.2 误判方向的差异

第二个对比是「错成什么样」。只看 ASR，RNTME-NAE 是 63%，基线是 45～47%；但把误判按方向拆开后，差异比数量上的差异更值得写：

表 3　各攻击的误判方向（四个目标合并）

攻击	成功数	成功样本均权重	危险占比/%	限速放宽	限速收紧	放宽/收紧
I-FGSM	1063	0.519	21.4	127	227	0.56
NAE	1052	0.524	21.8	128	220	0.58
DI-NI-FGSM	1016	0.518	21.1	122	214	0.57
RNTME-NAE	1348	0.520	23.6	207	222	0.93

基线把限速标志改错时，绝大多数是「往低改」——限速 80 读成 50、限速 70 读成 30，放宽/收紧比只有 0.55～0.58。这类错误车会开得更慢，属安全侧。RNTME-NAE 的比值是 0.93，几乎一半的限速误判是往高改：限速 50 读成 80、限速 70 读成 80。同样的「攻破」，后者才会让车超速。

需要克制的地方：成功样本的平均权重四者都在 0.50 上下，危险占比 21%～24%，差别不大。真正的差别在「放宽方向的绝对次数」——RNTME-NAE 是 207 次，基线是 122～128 次，约 1.7 倍。所以准确的表述是「RNTME-NAE 造成的放宽型误判在数量上明显更多」，而不是「它每次误判都更危险」。

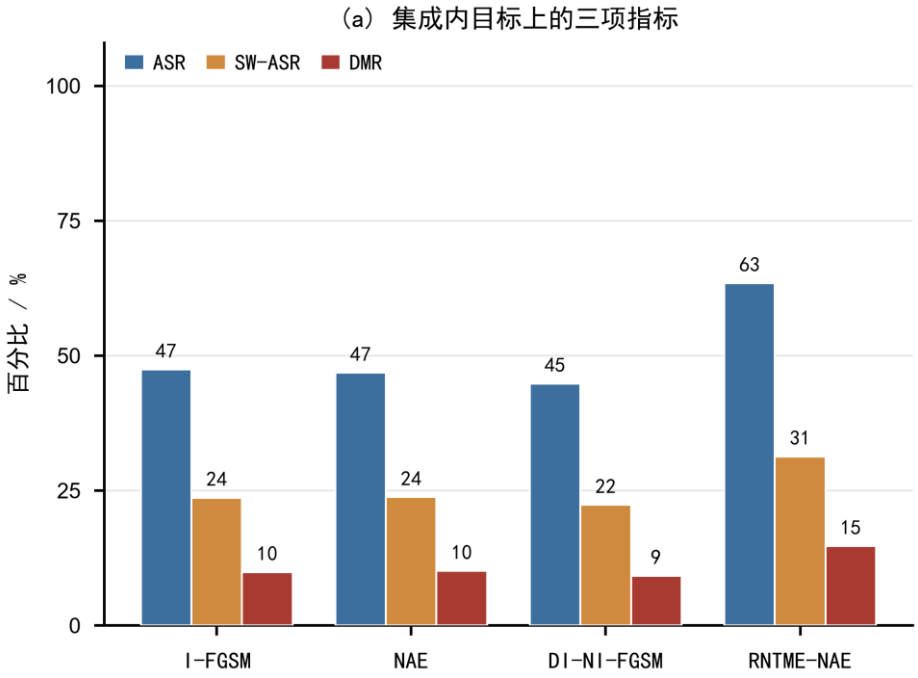


图 1　同一攻击在 ASR、SW-ASR、DMR 三个口径下的对比

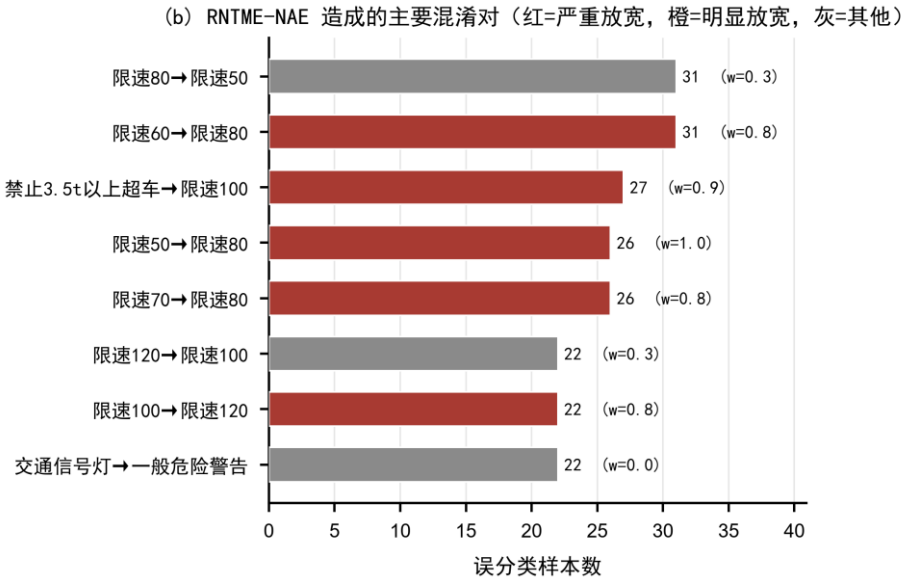


图 2　RNTME-NAE 造成的主要混淆对及语义权重

四、攻击实际把什么改成了什么

这一节是交通读者最关心的部分：不是「成功率多少」，而是「限速 30 被改成了什么」。下表把 RNTME-NAE 在各目标上最常见的混淆对合并统计。

表 4　RNTME-NAE 的主要混淆对（各目标合并）

混淆对	次数	权重	判定
限速 80 → 限速 50	31	0.3	更严格
限速 60 → 限速 80	27	0.8	严重放宽
限速 70 → 限速 80	22	0.8	严重放宽
禁止 3.5t 以上超车 → 限速 100	19	0.9	严重放宽
限速 50 → 限速 80	18	1.0	严重放宽
交通信号灯 → 一般危险警告	15	0.1	仅减速
限速 50 → 限速 30	14	0.3	更严格
限速 120 → 限速 100	13	0.3	更严格
限速 70 → 限速 30	12	0.3	更严格
限速 30 → 限速 70	8	1.0	严重放宽

论文里这张表应当按类别归一化成「占该类被攻击样本的比例」，并挑 3～4 个语义最重的案例配图（原图 / 对抗样本 / 判定标签）。

五、这批数据能写进论文吗

不能。以下五项与正式实验不同，混用会被审稿人抓住：

· 输入 32 px（高斯核 σ 相应取 1.5），正式实验为 224 px、σ=3；

· 替代模型为 4 个自建小网，正式实验须为 ResNet50 / EfficientNet-B0 / VGG19 / MobileNetV2 / GoogLeNet 五模型集成；

· 训练子集 12 000 幅、5 轮，正式实验为全量 39 209 幅、30 轮；

· 集成 M=3、未见目标 1 个，正式实验 M=5、未见目标 2 个（ResNet101 与 DenseNet121）；

· 单种子单次运行，正式实验需 5 个种子并报告均值±标准差与配对检验。

能写进论文的是三样东西：指标定义（SW-ASR / DMR）、权重表（需领域人员打分确认）、以及混淆对分析这个呈现方式。方法是新的，数字要换。

六、下一步

6.1 在有显卡的机器上跑全量

把整个 a11/ 目录连同 data/gtsrb 的三个 zip 拷过去，两条命令即可：

```
python -m a11.train --arch full --size 224 --epochs 30 --bs 64
python -m a11.eval_attack --size 224 --n 5000 --T 15 --sigma 3 --ensemble
resnet50,efficientnet_b0,vgg19,mobilenet_v2,googlenet --heldout resnet101,densenet121 --out full
```

6.2 权重表要找人打分

a11/swasr_weights.csv 是规则推导的版本（当前 v2，已修正「安全侧记 0」的过宽规则）。请 3 名交通工程或交通安全方向的人独立改分，取均值并报告 Kendall's W。论文里必须写明「权重由谁定、一致性多少」，否则 SW-ASR 会被质疑成作者自定义的凑数指标。

6.3 补三件试点没做的事

· ε 扫描（8/255、12/255、16/255），给出「隐蔽性—危害」曲线；

· 视频序列上的时间一致性（UA-DETRAC），报告逐帧翻转率；

· 与防御的交互（JPEG、位深缩减），验证低频扰动是否更耐压缩。