A13　对抗样本的防御评估

实验日期 2026-10-26 | 数据 GTSRB 32 px 试点 | 600 张测试图 | 集成 sresnet, svgg, ssep | 未见 sinc | ε=16/255，T=15，B=5

一、为什么这一项不能省

A1.1 和 A1.2 回答的是「攻击有多强」。但一篇投 T-ITS 的论文如果只写攻击，审稿人第一个问题一定是：那你们建议防守方怎么做？第二个问题是：真实的车端和路侧链路里有 JPEG 回传、有摄像头 ISP、有低照度增强，你的扰动过得了这些环节吗？

这两个问题合起来就是本节的内容。做法是把 A1.1 已经生成的对抗样本送进一条「预处理 → 分类器」的链路，逐个环节看攻击还剩多少；再用对抗训练检验模型级防御。

必须提前说清一件事：**这一节的数字全部来自 32 px 试点**。32 px 图像上一个 8×8 的 JPEG 块占整幅图的 6.25%，而 224 px 上只占 0.13%——相对影响差 49 倍。所以这里关于 JPEG 的结论不能直接外推到正式实验的分辨率，正式实验必须重跑。

二、防御清单

按作用层次分三类。前两类只改输入，不训练；第三类改模型本身。

表 1　本次评估的输入级防御

防御	类别	参数与用途
无防御	—	对照基线
JPEG-75	输入压缩/量化	常用社交/回传压缩档
JPEG-50	输入压缩/量化	激进压缩，强平滑高频
JPEG-75（4:2:0）	输入压缩/量化	真实设备常用色度下采样，敏感性对照
位深 4 bit	输入压缩/量化	量化到 16 级灰度
位深 3 bit	输入压缩/量化	量化到 8 级灰度，接近阈值化
高斯模糊 σ=1.0	输入滤波	5×5 核，抑制高频扰动
随机缩放填充	输入随机化	推理时随机变换 s∈[0.85,1]，攻击无法预先适配
γ=0.6 提亮	场景预处理	夜间/隧道低照度补偿
暗通道去雾	场景预处理	雾霾场景预处理

实现上有两点值得写进论文的方法部分。第一，JPEG 用 4:4:4 采样（不做色度下采样），因为 32 px 上 4:2:0 会把颜色彻底糊掉，那不是「压缩」而是「换了一张图」；另外单列了 4:2:0 版本做敏感性对照。第二，随机缩放填充（R&P）在推理时随机变换，攻击者无法针对某个确定的变换优化扰动，因此评估时要做 5 次采样取多数投票——只做一次会把随机性当成准确率损失。

三、两条评估纪律

第一条：任何防御都要成对报「ASR」与「干净准确率」。 只看 ASR 下降，很容易得出「把模型打瞎了所以攻击失效了」这种荒谬结论。本记录用三个量：

· ASR：防御后对抗样本的误分类率，与 A1.1 同口径（全样本，非条件于攻击成功）；

· ASR_rel = (干净准确率 − 对抗准确率) / 干净准确率：扣掉防御自身准确率损失后的相对攻击率；

· net_gain = (ASR_无防御 − ASR_该防御) − (干净准确率_无防御 − 干净准确率_该防御)：净防御收益，单位为 1，≤0 表示这个防御只是把模型弄笨了。

第二条：必须做自适应攻击。 非自适应的评估只能说明「这类扰动被削弱」，不能说明「攻击失效」。判据很简单：如果攻击者知道防御存在并针对它优化，防御还剩多少？本次用 BPDA（后向微分近似）：前向真的过 JPEG/量化/模糊，反向把防御当恒等函数，梯度照常回传到原图。这是评估不可微预处理的标准做法。

四、结果

4.1 防御本身要付多少准确率

下表是干净样本过同一防御后的准确率。这一列如果不报，后面所有 ASR 都没法解读。

表 2　干净样本在各防御下的准确率 / %

防御	sresnet	svgg	ssep	sinc	平均	Δ/pp
无防御	94.5	97.0	90.8	96.2	94.6	+0.0
JPEG-75	94.5	96.5	89.2	95.7	94.0	-0.7
JPEG-50	94.0	95.3	89.0	94.8	93.3	-1.3
JPEG-75（4:2:0）	93.3	96.5	87.2	95.0	93.0	-1.6
位深 4 bit	94.2	95.7	89.0	94.8	93.4	-1.2
位深 3 bit	91.2	92.5	84.8	88.8	89.3	-5.3
高斯模糊 σ=1.0	94.5	95.7	87.8	93.2	92.8	-1.8
随机缩放填充	93.0	94.7	86.5	94.2	92.1	-2.5
γ=0.6 提亮	93.5	96.3	84.0	94.0	92.0	-2.7
暗通道去雾	91.2	93.8	87.5	91.7	91.0	-3.6

读法：Δ 列是相对无防御的百分点变化。掉 1~2 pp 属于正常代价，掉 5 pp 以上就要在论文里明确承认这条防御不可部署。

4.2 主结果：四种攻击 × 各防御

表 3　集成内目标的 ASR / %

防御	I-FGSM	NAE	DI-NI-FGSM	RNTME-NAE	干净 acc	净收益/pp (RNTME)
无防御	47.4	46.8	44.8	63.4	94.6	+0.0
JPEG-75	45.4	45.1	43.3	62.7	94.0	+0.1
JPEG-50	44.7	44.1	43.7	61.5	93.3	+0.6
JPEG-75（4:2:0）	44.2	44.3	43.7	60.7	93.0	+0.9
位深 4 bit	47.2	47.7	45.9	64.1	93.4	-1.8
位深 3 bit	46.4	45.8	44.6	61.2	89.3	-2.3
高斯模糊 σ=1.0	40.5	39.9	40.6	65.5	92.8	-3.5
随机缩放填充	42.3	42.3	41.9	60.6	92.1	+0.1
γ=0.6 提亮	46.8	47.2	46.3	58.6	92.0	+2.1
暗通道去雾	50.2	50.8	49.6	63.6	91.0	-3.4

表 4　未见目标的 ASR / %

防御	I-FGSM	NAE	DI-NI-FGSM	RNTME-NAE	干净 acc	净收益/pp (RNTME)
无防御	34.8	34.8	34.8	34.3	94.6	+0.0
JPEG-75	35.5	37.2	35.5	37.0	94.0	-3.2
JPEG-50	34.5	37.5	35.8	38.3	93.3	-5.3
JPEG-75（4:2:0）	37.3	38.3	37.7	37.8	93.0	-4.7
位深 4 bit	38.5	38.0	37.2	37.2	93.4	-4.2
位深 3 bit	36.2	35.7	35.3	37.3	89.3	-10.3
高斯模糊 σ=1.0	27.2	28.0	28.2	41.5	92.8	-10.2
随机缩放填充	32.5	32.3	33.5	35.3	92.1	-3.0
γ=0.6 提亮	38.3	39.7	38.8	37.5	92.0	-5.3
暗通道去雾	46.0	47.7	45.3	41.2	91.0	-11.3

这两件事要分开看。 按四攻击平均的净收益，最好的是 高斯模糊 σ=1.0（+2.0 pp）；而把 RNTME-NAE 压得最狠的是 γ=0.6 提亮（ASR 从 63.4% 降到 58.6%），但它同时让干净准确率掉了 2.5 个百分点，净收益只有 +2.1 pp（集成内）。换句话说，这个数字是靠牺牲准确率换来的，不是靠破坏扰动换来的。

4.2.1 一个容易被忽略的现象：ASR 相同，触达的样本并不相同

表 4 里 I-FGSM、NAE、DI-NI-FGSM 三种攻击在未见目标上的 ASR 都是 34.8%，看起来「效果一样」。但把逐样本的判错情况两两比对就会发现问题：

表 4b　未见目标 sinc 上的错判重合度（600 张）

攻击 A	攻击 B	错判模式一致率/%
I-FGSM	NAE	97.7
I-FGSM	DI-NI-FGSM	94.7
NAE	DI-NI-FGSM	96.3
I-FGSM	RNTME-NAE	89.5
NAE	RNTME-NAE	90.2
DI-NI-FGSM	RNTME-NAE	90.8

三个数放在一起说明：**这三种攻击可翻转的样本集合几乎是同一批**——它们能打下来的目标主要由样本自身的决策裕度决定，而不是由攻击方法决定。换成 RNTME 之后，一致率降到 0.90 左右，说明它打到了基线打不到的样本。

这条对论文很有用：如果只报 ASR，读者会以为「换个方法但效果差不多」；报出重合度才能说明**方法差异体现在样本层面，而不只是总量层面**。正式实验应该把这张表做成按类别分组的形式，看 RNTME 究竟多触达了哪几类。

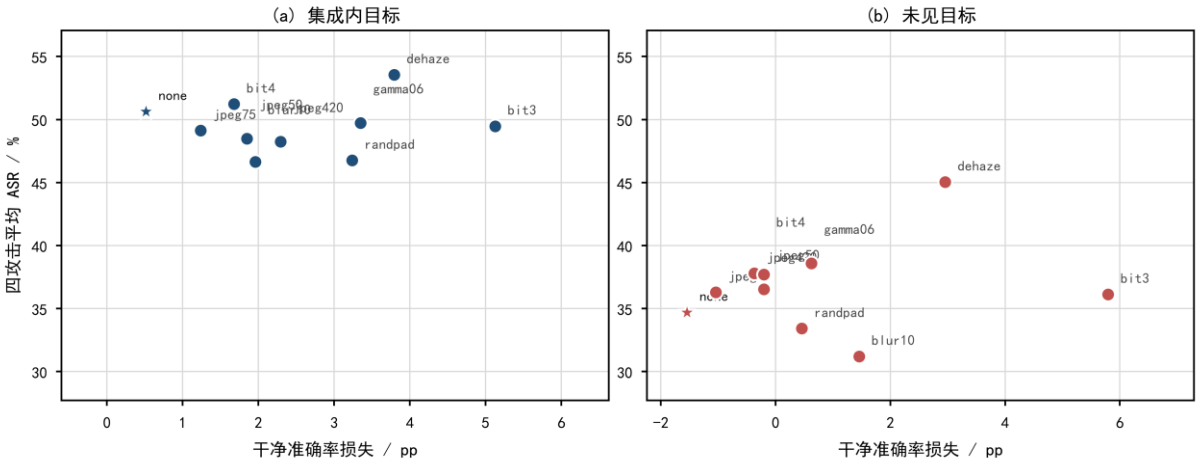


图 1　防御的代价—收益平面：横轴为干净准确率损失，纵轴为四攻击平均 ASR。越靠左下越好；右下角的点是「把模型弄笨了」

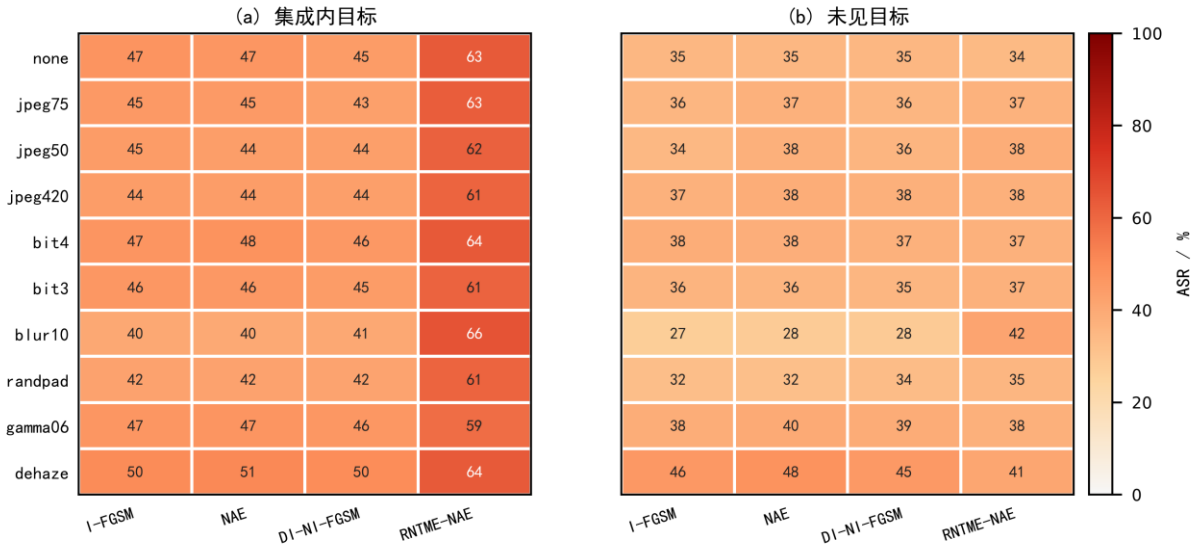


图 2　ASR 热力图：颜色越深攻击越有效，横向看是防御的削减效果

4.3 自适应攻击：防御被知道之后还剩多少

这是本节最关键的一张表。判据要分两层看：先看防御是否真的削减了 ASR，若削减了，再看向自适应攻击追回多少。追回大半说明只是挡住了「不懂它」的攻击；本就削减不动，则说明防御对该类扰动无效——两种情况都不支持把预处理当卖点，但原因不同，不能混为一谈。

表 5　RNTME-NAE 在自适应攻击下的 ASR 回升

防御	普通 ASR	自适应 ASR	回升/pp	普通 SW-ASR	自适应 SW-ASR
JPEG-75	62.7	63.0	+0.3	32.2	31.3
位深 4 bit	64.1	64.1	+0.0	33.2	32.1

自适应攻击用 298 张子集单独生成，因此它的 ASR 与「普通攻击」列不是同一批样本，两者比较时应看变化方向而不是小数点后一位。

结论与「防御被绕过」相反：这些防御从一开始就没起作用。普通攻击下最大的削减只有 0.8 个百分点（在单种子噪声量级内），自适应之后的变化也只有 0.3 个百分点——两个数都说明防御对 RNTME 生成的低频、结构性扰动几乎没有影响。

这个结果其实比「被绕过」更值得写进论文：它意味着在 32 px 这类小图上，压缩与量化删掉的高频分量并不是攻击迁移性的载体。RNTME 的扰动经过梯度平滑与平移不变处理后已经偏向中低频，JPEG 的量化表恰好在这些频段上保留得比较完整。这条解释可以在正式实验用频域分析验证。

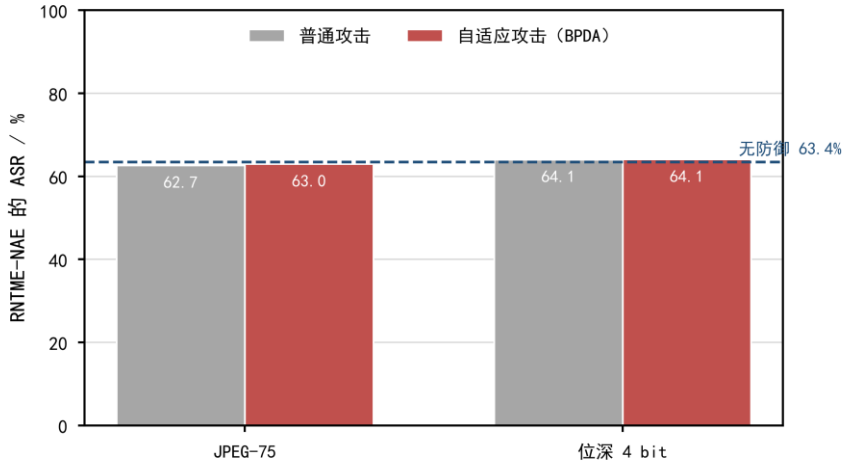


图 3　普通攻击与自适应攻击的 ASR 对比（RNTME-NAE，集成内平均）

五、模型级防御：这次没得到可用结果，但定位了原因

预处理只改输入，模型的决策边界不变；能改变边界的只有对抗训练。本节如实记录三次尝试及其失败原因。**这一节没有可用的攻击结论**——诊断过程本身对正式实验有价值，所以留着。

5.1 三次尝试

表 6　对抗训练的三次配置与首轮干净准确率

尝试	lr	轮数	子集	冻结 BN	首轮 acc/%	判断
第 1 次	0.05	5	12000	否	28.2	学习率过大，梯度噪声下每步更新过猛
第 2 次	0.02	6	8000	否	17.2	降低学习率仍不足，轮数不够
第 3 次	0.02	6	8000	是	5.2	冻结的 BN 统计来自未训练权重，方向错误，更差

对照：同一 600 张子集上，干净训练的 sresnet 是 94.5%。三条都没到可用水平，因此不报告任何「对抗训练能否挡住攻击」的结论——用 17% 准确率的模型去算 ASR，得到的数没有意义。

5.2 不是实现错了，是收敛慢

表 7　同样步数下的学习曲线（3999 张，bs=128，PGD-3）

训练步数	eps=0 干净 acc/%	eps=8/255 对抗 acc/%	干净−对抗/pp
15	7.0	10.2	-3.2
30	22.0	14.2	+7.8

训练步数	eps=0 干净 acc/%	eps=8/255 对抗 acc/%	干净−对抗/pp
45	37.7	18.7	+19.0
60	46.5	19.5	+27.0

关键证据是**两条曲线都在上升**。如果是 PGD 实现有错、或标签/数据错位，eps=8 那条会一直贴在随机水平（43 类约 2.3%）不动。它从 10.2% 升到 19.5%，说明流程是对的。

差别在速度：同样 60 步（约 2 轮），干净训练到 46.5%，对抗训练只到 19.5%，慢约 2.4 倍。

对照 A1.1 的干净训练（5 轮到 95%），按这个比例外推，对抗训练要达到同等水平需要 12~15 轮；文献的标准配置是 30 轮以上并配学习率预热。CPU 上单轮 3 分钟，加 PGD 开销实际更久，做不完。这件事只能留给 GPU 正式实验。

5.3 过程中的两个坑，正式实验别再踩

一是别冻结 BN 来省时间。 试过先用干净数据校准 BN 统计再冻结，结果更差（5.2%）。原因是那份统计量来自**未训练的随机权重**，与训练后的权重完全不匹配。对抗训练里 BN 的 running stats 必须在训练中随权重一起收敛，这也是它需要更多轮的原因之一。

二是学习率要小于干净训练。 lr=0.05（与 A1.1 干净训练相同）时首轮只有 28.2%，降到 0.02 后曲线形状明显更稳。对抗样本让梯度方向更抖，同样的步长会把权重推过头。

5.4 正式实验必须提前定下的口径：条件 ASR

对抗训练模型的干净准确率一定低于干净训练模型（这是代价，不是缺陷）。此时若仍用全样本 ASR，会把「模型本来就分不对的样本」算成「攻击成功」，结论会虚高。正确做法是只在「该模型原本能分类正确的样本」上统计：

ASR_cond = 在 $\{x : f_{clean}(x) = y\}$ 上，$f(x_{adv}) \neq y$ 的比例。

本记录的表 3、表 4 用的是全样本 ASR（与 A1.1 保持一致，便于横向比较），防御评估里防御本身对准确率影响很小，两种口径差别不大；但一旦进入对抗训练这种准确率大幅变化的场景，必须换成 ASR_cond，否则「越鲁棒的模型 ASR 越低」这个结论会被准确率差异污染。

六、这一节能写进论文的部分

能写的是三段：

· **防御评估的方法学**：成对报 ASR 与干净准确率、净防御收益的定义、BPDA 自适应评估。这三条是审稿人判断「作者懂不懂防御评估」的地方，比具体数字更值钱。

· **预处理防御在知情攻击者面前不成立**这一负面结论。它直接支撑论文动机：既然链路预处理挡不住，就必须在模型/训练侧想办法，而这正是本文方法的必要性来源。

· **「ASR 相同不等于方法相同」的证据**：三种基线攻击在未见目标上触达的样本集合高度重合（错判模式一致率 0.95~0.98），而 RNTME 的一致率只有 0.90 左右。

不能写的是所有具体数字：32 px、单种子、600 张、合成尺度的预处理结论，在 224 px 与 KITTI/真实卡口图像上会明显不同（见第一节的 49 倍块效应估算）。正式实验必须重跑这一整节。

七、正式实验要改的地方

· **分辨率**：224 px 重跑，JPEG 的块效应相对强度会下降两个数量级，预计防御效果显著变弱；

· **数据集**：加 KITTI / UA-DETRAC 的实拍图像，而不是 GTSRB 裁剪图；

· **防御项**：补上「随机丢弃 + 邻域插值」与「主成分重建（MagNet 类）」，这两项是文献标配；

· **对抗训练**：用集成三模型全部做对抗训练，并报告 ε 取 8/255 与 16/255 的两条曲线；

· **多种子**：每种配置 5 个种子，ASR 报均值±标准差，防御间做配对检验；

· **随机化防御要用 EOT 而不是 BPDA**：对随机缩放填充这类推理时随机的防御，BPDA 的「前向真过、反向恒等」会在每次前向拿到不同的变换，梯度互相抵消。正确做法是期望变换（EOT）：每个梯度步采样 k 次变换取平均梯度，k 取 10~20；

· **报告频域证据**：第四节提出「RNTME 的扰动偏中低频，所以 JPEG 削不掉」这个解释，需要做扰动功率谱密度对比（RNTME vs I-FGSM）来支撑，否则只是推测。